

INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE MONTERREY



Maestría en Inteligencia Artificial Aplicada (MNA)

Proyecto Integrador (TC5035)

Dra. Grettel Barceló Alonso

Dr. Luis Eduardo Falcón Morales

**Avance 4. Modelos alternativos**

**“Clasificación de ruido en laboratorio de motores eléctricos automotrices a través de métodos de inteligencia artificial”**

EQUIPO 14

Andrei García Torres A01793891

Emmanuel González Calitl A01320739

Denisse María Ramírez Colmenero A01561497

Fecha: 26 de mayo de 2024

## **ÍNDICE**

<b>Construcción de modelos alternativos</b>	<b>2</b>
<b>Comparación de rendimiento</b>	<b>2</b>
<b>Selección de los dos mejores modelos</b>	<b>4</b>
<b>Ajuste de los dos mejores modelos</b>	<b>5</b>
<b>Elección del modelo individual final</b>	<b>5</b>
<b>Bibliografía</b>	<b>6</b>

## **Construcción de 6 modelos diferentes, utilizando algoritmos variados.**

Se construyen los siguientes modelos con arquitecturas de Máquina Soporte Vectorial, Redes Neuronales Recurrentes y de Redes Neuronales Convolucionales para comparar el desempeño de los diferentes algoritmos para la clasificación binaria de los espectrogramas de las imágenes de ruido que han sido clasificadas como OK y NOK. Los algoritmos de los modelos y los entrenamientos pueden ser consultados en el siguiente repositorio en la carpeta de Github destinada para el proyecto integrador, a través de la siguiente liga.

[https://github.com/emm-gl/project\\_mna/tree/main/Modelos%20Alternativos%20Avance%204](https://github.com/emm-gl/project_mna/tree/main/Modelos%20Alternativos%20Avance%204)

1. CNN\_Noise\_v01
2. CNN\_Noise\_v02
3. Keras\_Noise\_Version1
4. Keras\_Noise\_Version2
5. SVM\_Noise\_Version1
6. SVM\_Noise\_Version2
7. SVM\_Noise\_Version3

El resultado de los entrenamientos y las métricas de estos modelos se utilizarán para realizar las comparativas que servirán de apoyo en la selección y ajuste de los modelos finales.

## **Comparación del rendimiento de los modelos obtenidos**

A continuación se presenta una tabla comparativa como resumen para el análisis de los modelos propuestos, donde se muestran los resultados de las métricas obtenidas en los entrenamientos para la clasificación de ruido binaria.

Las características que se consideran para la selección de los modelos son el criterio de sobreentrenamiento y los valores del accuracy, precisión, recall y F1 score en los resultados de la validación de cada modelo. De tal modo se presenta el resultado de las matrices de confusión obtenidas para cada modelo evaluado durante la validación.

Respecto al tiempo de entrenamiento, se concluyó que este no era un factor determinante para seleccionar los mejores modelos ya que los tiempos de ejecución son relativos dependiendo la máquina utilizada y la interfaz. Por otra parte, utilizando la misma máquina e interfaz, el tiempo de ejecución de los modelos construidos no es más de cinco minutos.

El cuadro comparativo puede ver también en la siguiente liga del repositorio: [https://github.com/emm-gl/project\\_mna/blob/main/Modelos%20Alternativos%20Avance%204/Cuadro%20comparativo%20de%20los%20Modelos%20Alternativos%20-%20Hoja%201.pdf](https://github.com/emm-gl/project_mna/blob/main/Modelos%20Alternativos%20Avance%204/Cuadro%20comparativo%20de%20los%20Modelos%20Alternativos%20-%20Hoja%201.pdf)

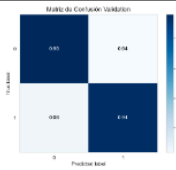
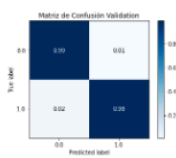
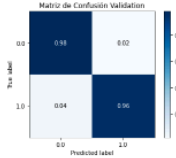
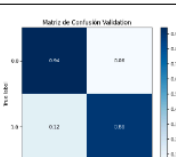
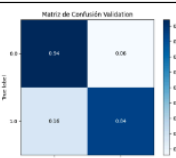
	Sobreentrenamiento	Accuracy	Matriz de Confusión	Precisión	Recall	F1 Score
CNN_Noise_v01.ipynb	TRUE	0.95		0.95	0.95	0.95
CNN_Noise_v02.ipynb	FALSE	0.87		0.87	0.85	0.85
Keras_Noise_Version1.ipynb	TRUE	0.98		0.98	0.98	0.98
Keras_Noise_Version2.ipynb	FALSE	0.97		0.97	0.97	0.97
SVM_Noise_Version1.ipynb	TRUE	0.85		0.85	0.85	0.85
SVM_Noise_Version2.ipynb	TRUE	0.91		0.91	0.91	0.91
SVM_Noise_Version3.ipynb	TRUE	0.89		0.89	0.89	0.89

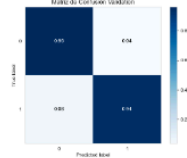
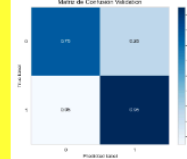
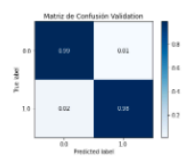
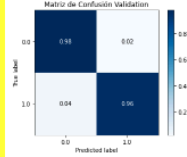
Tabla 01 Comparativa de modelos

## Selección de dos modelos que proporcionan el mejor rendimiento.

Después de descartar los modelos que presentan sobre entrenamiento se selecciona un modelo de redes neuronales recurrentes y otro de redes neuronales convolucionales con los mejores resultados en las métricas de validación. A través de la siguiente tabla comparativa se puede visualizar la selección de los dos mejores modelos, donde también se toman como criterio que los modelos tengan los mejores resultados los valores del accuracy, precisión, recall y F1 score en los resultados de la validación de cada modelo.

**CNN\_Noise\_v2**

**Keras\_Noise\_v2**

	Sobreentrenamiento	Accuracy	Matriz de Confusión	Precisión	Recall	F1 Score
CNN_Noise_v01.ipynb	TRUE	0.95		0.95	0.95	0.95
CNN_Noise_v02.ipynb	FALSE	0.87		0.87	0.85	0.85
Keras_Noise_Version1.ipynb	TRUE	0.98		0.98	0.98	0.98
Keras_Noise_Version2.ipynb	FALSE	0.97		0.97	0.97	0.97

*Tabla 02 Selección de modelos con mejor rendimiento*

## Ajuste de los dos mejores modelos.

Los dos mejores modelos seleccionados han sido ajustados en los hiperparámetros como el número de capas tanto en las redes neuronales recurrentes como en las capas de las redes neuronales convolucionales, el número de épocas de entrenamiento, la cantidad de píxeles de las imágenes para el entrenamiento.

Keras\_Noise\_v03\_Ajustado

CNN\_Noise\_v03\_Ajustado

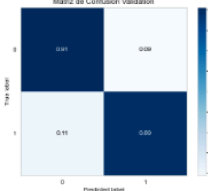
	Sobreentrenamiento	Accuracy	Matriz de Confusión	Precisión	Recall	F1 Score
Keras_Noise_Version3_Ajustado.ipynb	FALSE	0.79		0.79	0.79	0.79
CNN_Noise_v03_Ajustado.ipynb	FALSE	0.90		0.90	0.90	0.90

Tabla 03 Métricas de modelos seleccionados con mejor ajuste

## Elección del modelo individual final

CNN\_Noise\_v03\_Ajustado

El modelo seleccionado muestra un rendimiento sólido y equilibrado en la clasificación de imágenes de las pruebas de ruido, con métricas de precisión, recall y f1-score consistentemente altas (0.90) para ambas clases (OK y NOK). Esto sugiere que el modelo es fiable y tiene un buen desempeño general en la tarea de clasificación de imágenes defectuosas (con ruidos intensos) como en identificar imágenes correctas.

Como se comentó en el avance anterior, era esencial para la empresa que el modelo tuviera buena predicción tanto de verdaderos negativos como verdaderos positivos, analizando la matriz de confusión se puede concluir que el modelo cumple con lo requerido.

## Bibliografía

Bulentsiyah. (2019, 12 enero). *Dogs vs. Cats Classification (VGG16 Fine Tuning)*. Kaggle.

<https://www.kaggle.com/code/bulentsiyah/dogs-vs-cats-classification-vgg16-fine-tuning>

Chávez, S. R. (2024, 9 mayo). *Teaching a Machine to Learn Command Voices*.

<https://www.linkedin.com/pulse/teaching-machine-learn-command-voices-santiago-reyes-ch%2525C3%2525A1vez-vm2cc/?trackingId=UAoFhFMITaeq479XXyb15A%3D%3D>

Francois Chollet. (2021). *Deep Learning with Python, Second Edition*. Manning.

Perez, R. (2023, 29 noviembre). *Clasificación de imágenes con redes profundas - Raul Perez*

- *Medium*. *Medium*.

<https://medium.com/@raulpzs/clasificaci%C3%B3n-de-im%C3%A1genes-con-redes-profundas-3a3b747489dc>

Prathap, P. (2023, 28 julio). *The Secret to Understanding CNNs: Convolution, Feature Maps,*

*Pooling and Fully Connected Layers!* *Medium*.

<https://medium.com/@prajeeshprathap/the-secret-to-understanding-cnns-convolution-feature-maps-pooling-and-fully-connected-layers-97055431a847>

Rodríguez, E. (2023, 7 octubre). *La Importancia de la Función de Pérdida en Machine*

*Learning*. *Canal* *Innova*.

<https://canalinnova.com/la-importancia-de-la-funcion-de-perdida-en-machine-learning/>

Verdeguer, J. (2020). *Redes neuronales para la clasificación y segmentación de imágenes médicas* [Tesis de maestría, Universitat Politècnica de València]. Recuperado 16 de mayo de 2024, de <https://m.riunet.upv.es/bitstream/handle/10251/158739/Verdeguer%20-%20Redes%20neuronales%20para%20la%20clasificación%20y%20segmentación%20de%20imágenes%20médicas.pdf?sequence=1&isAllowed=y#:~:text=Las%20redes%20densas%20son%20las,neurona%20de%20la%20capa%20anterior.>